滚动字幕的检测与拼接

一、实验要求

1. 在一段视频中，对于一个给定的字幕区域，判断其是否为滚动字幕。
2. 对于滚动字幕，将其拼接为完整的字幕条。
3. 对于固定字幕，直接将其输出。

我借助了 opencv 完成了实验（opencv 4.9.0，Visual Studio 2022，windows 11）。

二、实验内容

（一）判断是否为滚动字幕

1. 确定字幕区域

根据图片，人工确定[x,y,width,height]，以确定字幕区域。

2. 滚动字幕判断

我使用了一个启发式的判断方法，来区分滚动字幕和固定字幕。该步骤在第（二）节第 3 小节得到 good_matches 之后。

首先定义一个 map，它的 key 值为两点间的 L1 距离，value 值为出现次数。

```
map<double, int> count;//L1 距离 出现次数
```

然后，遍历 good_matches，计算 match 的两个点间的 L1 距离，并加入 map 中：

```
for (int i = 0; i < good_matches.size(); i++) {
.....
 int x1 = kps1[good_matches[i].queryIdx].pt.x;
 int y1 = kps1[good_matches[i].queryIdx].pt.y;

 int x2 = kps2[good_matches[i].trainIdx].pt.x;
 int y2 = kps2[good_matches[i].trainIdx].pt.y;

 int L1 = abs(x1 - x2) + abs(y1 - y2);

 if (count.find(L1) == count.end()) {
  //key 不存在
  count.insert(pair<double, int>(L1, 1));
 }
 else {
  map<double, int>::iterator it = count.find(L1);
  it->second = it->second + 1;
```

```
    }
}
```

接着，根据 value 值，对 map 从大到小排序：

```
vector< pair<double, int> > vec;
for (map<double, int>::iterator it = count.begin(); it != count.end(); it++) {
    vec.push_back(pair<double, int>(it->first, it->second));
}
sort(vec.begin(), vec.end(), [](pair<double, int>a, pair<double, int>b) {return a.second > b.second; });
```

最后，判断出现次数最大的 L1 距离，是否小于 60（经验值），如果小于，判断为固定字幕，退出；否则，认定为滚动字幕，继续接下来的步骤。vec.size() == 0 是为了避免 vec 为空而出现异常。

```
/*==========判断是否为滚动字幕==========*/
if (vec.size() == 0 || vec[0].second < 60) {
    //根据相似点匹配数量进行判断
    cout << endl;
    cout << "================================" << endl;
    cout << "           不是滚动字幕" << endl;
    cout << "================================" << endl;
    Mat res;
    vconcat(image2, image1, res);
    imwrite(output_fix, res);
    return;
}
else {
    cout << endl;
    cout << "================================" << endl;
    cout << "           是滚动字幕" << endl;
    cout << "================================" << endl;
}
```

我选择这种启发式判断方法的依据是，滚动字幕匹配到的特征点，具有平移关系，所以具有相同 L1 距离的滚动字幕的匹配特征点的数量应该比固定字幕的多。

（二）滚动字幕的拼接

我自定义一个函数用于滚动字幕的拼接，其中有四个参数：

- string left: 要拼接的左边图的地址
- string right: 要拼接的右边图的地址
- Rect roi: 字幕区域

- bool processed：右图是否已经根据 roi 裁剪过（这是为了能够连续拼接多张图）

```
void mystitch(string left, string right, Rect roi, bool processed = false)
```

接下来对该函数的实现进行介绍：

1. 读取图片

设置保存地址，如果为滚动字幕，存储在 output_roll 中；反正存储在 output_fix 中；接着进行对图片的预处理操作，首先使用 imread 读取图片，然后对右图进行裁剪得到字幕区域；根据传入的 processed，判断左图是否需要裁剪，并根据判断结果进行不同操作。注意，最终 image1 存储的是右图的字幕区域。image2 存储的是左图的字幕区域。

```
string output_roll = "result/roll.jpg";
string output_fix = "result/fix.jpg";

// [预处理]
Mat src1 = imread(left);
Mat src2 = imread(right);

/*
* 提取 ROI 区域
* x y width height
*/
//获取 ROI 区域，这是要拼接的滚动字幕区域
Mat image1 = src2(roi);//右图
Mat image2;//左图
if (processed) {
 image2 = src1;
}
else {
 //如果传入的是未处理的原始图像，直接赋值
 //（为了能够多次拼接）
 image2 = src1(roi);
}

imwrite("result/right.jpg", image1);
imwrite("result/left.jpg", image2);
```

2. 计算特征点和描述子[1]

我使用了 SIFT 算法进行图片特征点的检测，得到图片 image1 和 image2 的特征点集合 kps1 和 kps2。SIFT 检测器得到的 KeyPoint 的内容如下：

- 关键点的坐标位置 （x, y）
- 关键点的尺度大小

[1] 该小节和第 3 小节内容的原理来自 D.Lowe 的论文 Distinctive Image Features from Scale-Invariant Keypoints，本人未阅读，在此仅作为说明。

- 关键点的方向角度（为每个特征点指定方向，以实现图像旋转的不变性）
- 关键点的响应值 （表示关键点的显著性），SIFT 默认以 0.03 作为阈值
- 其他可能的属性或描述符

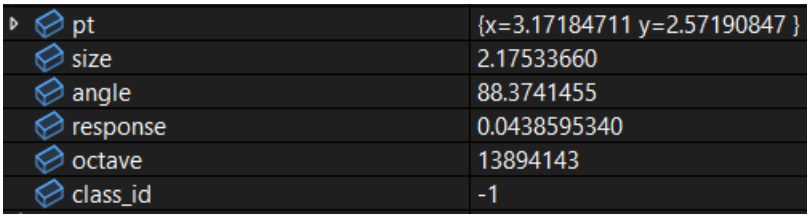

图 1 KeyPoint 的值

得到特征点后，就可以进行特征描述子的计算。在特征点（KeyPoint）周围选取 16x16 的邻域。将它为 16 个 4x4 大小的子块。对于每个子块，创建包含 8 个 bin [2]的方向直方图。因此总共有 128 个 bin 值可用（如下图中的 cols = 128）。由这 128 个形成的向量构成了特征点描述子。如下所示，特征描述子记录了特征点的一些信息，比如“rows = 475”表示共有 475 个特征点。

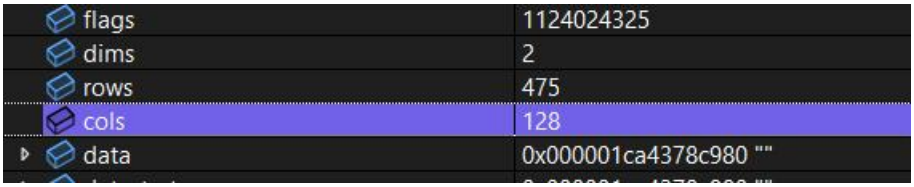

图 2 特征描述子部分内容

```
// [SIFT]
//检测特征点
Ptr<SIFT> detector = SIFT::create();
vector<KeyPoint> kps1, kps2;
detector->detect(image1, kps1);
detector->detect(image2, kps2);

//计算特征描述符
Mat descriptors1;
Mat descriptors2;
detector->compute(image1, kps1, descriptors1);
detector->compute(image2, kps2, descriptors2);
//绘制特征点
//draw_feature(image1, kps1, descriptors1);
//draw_feature(image2, kps2, descriptors2);
// [SIFT]
```

3. 匹配特征

使用 opencv 的 BruteForce 匹配器进行特征匹配。其中的 knnMatch 函数，对于每个查询

[2] bin 值指的是方向直方图中每个柱子的值，用来表示该子块内的梯度方向信息。

特征描述子，它会计算与其最接近的 k 个训练特征描述子，并返回这 k 个最近邻的距离。这样可以得到更多的匹配结果，但也可能包含一些不太准确的匹配。（使用 knnMatch 函数时，设置 k=2，然后可以计算最近距离与第二最近距离的比率。如果比率大于 0.8，则忽略它们。根据脚注 1，这样做消除了大约 90%的错误匹配，而同时只去除了 5%的正确匹配）

```
// [BruteForce Matcher]
//创建特征点匹配器
Ptr<DescriptorMatcher> matcher = DescriptorMatcher::create("BruteForce");
//进行特征匹配
/*
class DMatch{
 ...
 int queryIdx; // 特征点在第一幅图像中的索引
 int trainIdx; // 特征点在第二幅图像中的索引
 float distance; // 两个特征点之间的距离
};
*/
vector<vector<DMatch>> matches;
vector<DMatch> good_matches;
//matcher->match(descriptors1, descriptors2, matches);//vector<DMatch> matches
matcher->knnMatch(descriptors1, descriptors2, matches, 2);//k=2

// Lowe's algorithm,获取优秀匹配点
for (int i = 0; i < matches.size(); i++)
{
 if (matches[i][0].distance > 0.8 * matches[i][1].distance)
 {
  //最近距离与第二最近距离的比率，大于 0.8，则忽略它们
  //消除了大约 90%的错误匹配，而同时只去除了 5%的正确匹配
 }
 else {
  good_matches.push_back(matches[i][0]);
 }
}
```

4. 根据匹配到的特征，计算单应性矩阵

首先，得到源点和目的点：

```
vector<Point2f> srcPoints, dstPoints;
for (int i = 0; i < good_matches.size(); i++) {
 srcPoints.push_back(kps1[good_matches[i].queryIdx].pt);
 dstPoints.push_back(kps2[good_matches[i].trainIdx].pt);
}
```

然后使用 opencv 的 RANSAC 算法计算单应性矩阵，用于透视校正或图像对齐：

```
Mat H = findHomography(srcPoints, dstPoints, RANSAC);
```

5. 对图片进行透视变换

首先，使用 opencv 的 warpPerspective 方法对右侧图像（image1）进行透视变换，设置变换后的图片宽度为原始图像的两倍，高度相同：

```
//对图像进行透视变换
Mat imageTransform1, imageTransform2;
//warpPerspective(image1, imageTransform1, H, Size(image1.cols + image2.cols, image2.rows));
warpPerspective(image1, imageTransform1, H, Size(image1.cols + image2.cols, image2.rows));
```

得到的某个右图输出如下所示：

图 3 透视变换 1

然后，将左侧图像拷贝到透视变换的图像中：

```
//图像拷贝
//创建拼接后的图,需提前计算图的大小
int dst_width = imageTransform1.cols;  //取最右点的长度为拼接图的长度
int dst_height = image2.rows;

Mat dst(dst_height, dst_width, CV_8UC3);
dst.setTo(0);

imageTransform1.copyTo(dst(Rect(0, 0, imageTransform1.cols, imageTransform1.rows)));
image2.copyTo(dst(Rect(0, 0, image2.cols, image2.rows)));//复制到左边
```

得到的图像如下所示：

图 4 透视变换 2

注意到右侧有黑边，为了美观也为了能够拼接多个滚动字幕，我进行了消除黑色区域的操作。

6. 其他操作

(1) 去除右侧黑色区域

定义了一个函数 delete_black，用于消除右侧的黑色区域，如下所示，先将 RGB 图像转

为灰度图像，然后再转为二值图像，接着我利用 opencv 自带的函数 boundingRect 进行分割，得到一个矩形框，该矩形块包含的是非黑色区域内容，如图 5 所示。接着只保留矩形框区域即可，最终得到的图如图 6 所示。

（Sample1/016660.jpg Sample1/016717.jpg 165, 520, 550, 50）

```
void delete_black(Mat& image) {
 //去除右侧黑边

 int rs = image.rows;
 int cs = image.cols;

 try {
  // 转换为灰度图像
  Mat grayImage;
  cvtColor(image, grayImage, cv::COLOR_BGR2GRAY);

  // 阈值处理
  Mat binaryImage;
  threshold(grayImage, binaryImage, 1, 255, cv::THRESH_BINARY);

  // 使用boundingRect 确定黑边范围
  Rect boundingRect = cv::boundingRect(binaryImage);

  // // 在原始图像上绘制边界矩形
  //rectangle(image, boundingRect, cv::Scalar(0, 255, 0), 2);

  image = image(boundingRect);
  //show(image);

  //cout << rs << " " << cs << endl;
  //cout << image.rows << " " << image.cols << endl;
 }
 catch (Exception e) {
  cout << e.err;
 }

}
```

图 5 矩形框

图 6 拼接结果

去除了黑框以后，就能进行以拼接结果作为左图，新的图作为右图，进行连续拼接了。（如图 7 所示）

（图 6 Sample1/016816.jpg 165, 520, 550, 50）

```
//连续拼接
string left = "result/roll.jpg";
string right = "Sample1/016816.jpg";

mystitch(left, right, roi[0], true);
```

图 7 多次拼接结果

三、测试

（一）测试 1：滚动字幕

图 8 left

图 9 right

图 10 合并

（二）测试 2：固定字幕

这两个数据是玩自己创建[3]。

图 11 left

图 12 right

判定为固定字幕，我将两个图片上下拼接，然后保存拼接后的图片。

[3]https://tv.cctv.com/2024/05/01/VIDEyGVj8XoEEcIFwer6XKy5240501.shtml?spm=C45404.P9Z56wAyBcZ2.E8JlE0NUktSy.2 中的 2:51 和 3:11 的截图。

图 13 固定

（三）测试 3：多个滚动字幕拼接

图 14 left

图 15 right1

图 16 right2

图 17 合并

（四）测试 4：距离很近的滚动字幕，判断为 是滚动字幕

图 18 left

图 19 right

图 20 合并

四、存在问题

（一）测试 5：距离很远的滚动字幕，判断为 不是滚动字幕

我的算法，会将此种情况的字幕，判断为固定字幕。

图 21 left

图 22 right

判断为固定字幕：

图 23 固定

（二）测试 6：两个不同帧但相同的固定字幕

我的算法会将此种情况，判断为滚动字幕。

图 24 left

图 25 right

图 26 合并

（三）思考

1. 给定的样本不含有下面情况的固定字幕，即两帧的固定字幕不同。

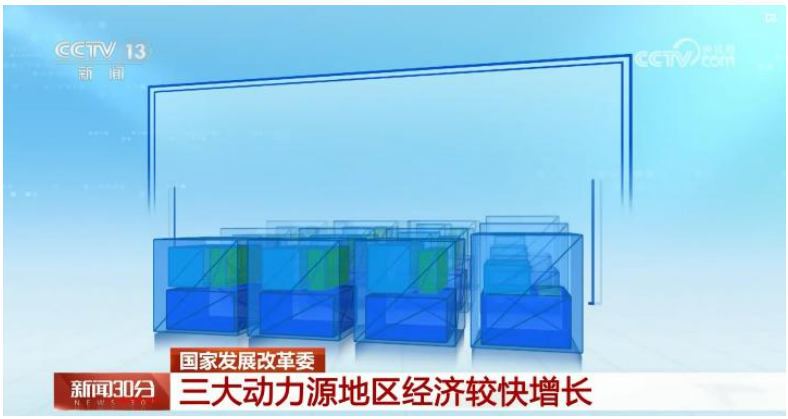

2. 我的算法会将距离很长的两帧的滚动字幕判定为固定字幕，以及会将不同帧但内容相同的固定字幕判定为滚动字幕；我觉得这两种情况应当不予讨论，我认为滚动字幕总有一部分文字相同，而固定字幕应当具有不同文字。另一方面，我暂时找不出这个问题的解决办法。

3. 我遇到的主要问题，就是如何区分滚动字幕和固定字幕，我放到了最后才解决这个问题。我是假设滚动字幕的字体是平移过去的，因此滚动字幕的匹配特征点应当具有大量相等的距离，我也是基于此来进行二者的区分的。除此之外，我还有另外一个想法，滚动字幕应当有部分连续的字体相同，因此可以识别出字体，然后进行判断，但此种方法未进行实践。

4. 我目前未能很好的理解单应性矩阵以及透视变换的原理，对它们的理解仅仅停留在单应性矩阵是确定四个点位置，并在不同的视图角度中均能确定这四个位置；透视变换是将图片将图片投影到一个新的视平面，即投影映射。